

זיהוי מטרת שינוי וחוסרים פונקציונליים בקוד

RTL

Deep Learning Project

15 min

Final Presentation

הבעיה: שינוי קטן עלול להסתיר חוסר גדול

DiffIntent-RTL

```
@@ always_ff @(posedge clk_i) @@  
- if (!rst_ni) state_q <= IDLE;  
+ if (!rst_ni) state_q <= IDLE;  
+ else if (req_i) begin  
+   state_q <= BUSY;  
+   valid_o <= 1'b1;  
+ end
```

What if the final assignment is missing?

השינוי עדיין יכול להיות תקין
תחבירית
**אבל ההתנהגות הרצויה אינה
שלמה**

מפתח אנושי קורא הקשר, מבנה והבדלים
בין שורות. המודל חייב לקבל את אותם
רמזים.

Code Review

Completeness

האם השינוי נראה שלם?

binary task


Intent

איזו מטרה עומדת מאחורי השינוי?

4 classes






ההשערה

ייצוג היררכי שמבחין בין שורות שנוספו, נמחקו ונשמרו ישפר את זיהוי החוסר.




היחידה נשמרת כ- diff ברמת קובץ, והזוג המקורי והסינתטי נשאר באותו split.

Dataset Overview




5,903

raw candidates



2,843

weak-labeled real



5,500

after synthetic holes

train 3,873 validation 830 test 797

SYNTHETIC HOLE

```
+ if (req_i) begin  
+   state_d = BUSY;  
  
+ end
```

COMPLETE

```
+ if (req_i) begin  
+   state_d = BUSY;  
+   valid_d = 1'b1;  
+ end
```



drop_added_line

82.2%

of test synthetic examples

ארבע משפחות מודלים ברמות מורכבות שונות

DiffIntent-RTL

1

TF-IDF + Logistic Regression

sparse lexical features

2

MLP

pooled token embeddings

3

BiGRU

flat sequence encoder

4

Hierarchical Transformer

line encoder + diff structure

Multi-task head

אותו ייצוג משמש לשתי משימות, עם פלט נפרד לכל משימה.

Intent Completeness


הארכיטקטורה ההיררכית שומרת את מבנה ה-diff

DiffIntent-RTL



ADD DEL
CONTEXT

מוסיף למודל מידע מפורש על תפקיד כל שורה בתוך השינוי.
line-type embedding



0.4197

test Macro-F1


TF-IDF

האות הלקסיקלי הספיק כדי
לעקוף את המודלים העמוקים.

refactor_cleanup

Control experiment חושף דליפה מהותית


DiffIntent-RTL




0.9855

Macro-F1

המדד כמעט משחזר את מנגנון התיוג, ולכן אינו הוכחה להבנת קוד טהורה.



hole F1




AUROC




false positives

Hole Confusion Matrices (Row-Normalized)








Δ hole F1



Δ AUROC

Ablation Results on the Full Experiment



82.2%

drop_added_line



mutation distribution

נדרש סט בדיקה ידני של
חוסרים אמיתיים.

~~Synthetic Coverage~~


רוב הדוגמאות נוצרו מהסרת שורה
שנוספה.

~~Rare Mutations~~

יש מעט דוגמאות לשינויים סמנטיים
עדינים.

~~External Validity~~


לא בוצעה הערכה סופית על פרויקט
חיצוני.

**0.4197**

Intent Macro-F1

ייצוג מבנה השינוי חשוב יותר מנפח המודל.


1

**0.6029**

hole F1

line-type מצמצם התראות שווא ומשפר זיהוי חוסר.

2


**0.7352**


hole AUROC

Intent labels $\neq$ commit message


3

נדרש מקור תוויות עצמאי.







Improved Weak Labeling



Hardware-aware Features



Cross-project Study



Medium-scale studies

המספרים אינם בני השוואה ישירה לניסוי המלא. הם מצביעים על שיפור כיסוי התיוג, ערך של מאפייני חומרה ופער בין פרויקטים.