

DiffIntent-RTL

זיהוי מטרת שינוי וחוסרים פונקציונליים
בקוד

RTL

Deep Learning Project

קורן הנס | נועה סבג

15 min

Final Presentation

```
@@ always_ff @(posedge clk_i) @@  
- if (!rst_ni) state_q <= IDLE;  
+ if (!rst_ni) state_q <= IDLE;  
+ else if (req_i) begin  
+   state_q <= BUSY;  
+   valid_o <= 1'b1;  
+ end
```

What if the final assignment is missing?

השינוי עדיין יכול להיות תקין
תחבירית
**אבל ההתנהגות הרצויה אינה
שלמה**

מפתח אנושי קורא הקשר, מבנה והבדלים
בין שורות. המודל חייב לקבל את אותם
רמזים.

Code Review

מפתח אנושי קורא יחד את ההקשר, המבנה
וההבדל בין השורות.

שתי שאלות מחקר, אובייקט למידה אחד

Completeness

האם השינוי נראה שלם?

binary task

Intent

איזו מטרה עומדת מאחורי השינוי?


4 classes

ההשערה

ייצוג היררכי שמבחין בין שורות שנוספו, נמחקו ונשמרו ישפר את זיהוי החוסר.





CC2Vec PatchNet DeepJIT CodeReviewer

מהיסטוריית קוד לניסוי מבוקר



כל שינוי נשמר ברמת קובץ, והזוג המקורי והסינתטי נשאר באותה חלוקה.

Dataset Overview



5,903

raw candidates

2,843

weak-labeled real

5,500

after synthetic holes

train 3,873 validation 830 test 797

SYNTHETIC HOLE

```
+ if (req_i) begin  
+   state_d = BUSY;  
  
+ end
```

COMPLETE

```
+ if (req_i) begin  
+   state_d = BUSY;  
+   valid_d = 1'b1;  
+ end
```



drop_added_line

82.2%

of test synthetic examples

השוואת ארבע משפחות מודלים

4

**Hierarchical
Transformer**

line encoder + diff
structure

3

BiGRU

flat sequence encoder

2

MLP

pooled token
embeddings

1

**TF-IDF + Logistic
Regression**

sparse lexical features

Multi-task head


ייצוג משותף לשתי המשימות, עם פלט נפרד לכל משימה.



ADD DEL
CONTEXT

line-type embedding

מידע מפורש על תפקיד כל שורה בתוך השינוי.

**0.4197**

test Macro-F1

TF-IDF

קו הבסיס השיג את התוצאה הטובה ביותר. האות הלקסיקלי הספיק כדי לעקוף את המודלים העמוקים.

refactor_cleanup

בדיקת בקרה חושפת דליפה

message-only
model




← weak label

← commit message


0.9855

Macro-F1

המדד כמעט משחזר את מנגנון התיוג, ולכן אינו הוכחה להבנת קוד טהורה.




Hole Confusion Matrices (Row-Normalized)





Ablation Results on the Full Experiment



מה המודל עדיין לא הוכיח

Synthetic Coverage


רוב הדוגמאות נוצרו מהסרת שורה שנוספה.

Rare Mutations

יש מעט דוגמאות לשינויים סמנטיים עדינים.

External Validity

לא בוצעה הערכה סופית על פרויקט חיצוני.



נדרש סט בדיקה ידני של
חוסרים אמיתיים.

0.4197

Intent Macro-F1

ייצוג מבנה השינוי חשוב יותר מנפח המודל.

1

0.6029

hole F1

מידע מפורש על סוג השורה מצמצם התראות שווא ומשפר זיהוי חוסר.


2


0.7352

hole AUROC


מקור התוויות חייב להיות עצמאי ממנגנון התיוג.

3







Improved Weak Labeling



Hardware-aware Features



Cross-project Study



Medium-scale studies

המספרים אינם בני השוואה ישירה לניסוי המלא. הם מצביעים על שיפור כיסוי התיוג, ערך של מאפייני חומרה ופער בין פרויקטים.