

# DiffIntent-RTL

זיהוי מטרת שינוי וחוסרים פונקציונליים  
בקוד

RTL

---

Deep Learning Project

קורן הנס | נועה סבג

15 min

Final Presentation

```
@@ always_ff @(posedge clk_i) @@  
- if (!rst_ni) state_q <= IDLE;  
+ if (!rst_ni) state_q <= IDLE;  
+ else if (req_i) begin  
+   state_q <= BUSY;  
+   valid_o <= 1'b1;  
+ end
```

What if the final assignment is missing?

השינוי עדיין יכול להיות תקין  
תחבירית  
**אבל ההתנהגות הרצויה אינה  
שלמה**

מפתח אנושי קורא הקשר, מבנה והבדלים  
בין שורות. המודל חייב לקבל את אותם  
רמזים.

Code Review

מפתח אנושי קורא יחד את ההקשר, המבנה  
וההבדל בין השורות.

## Completeness

האם השינוי נראה שלם?

binary task

## Intent

איזו מטרה עומדת מאחורי השינוי?


4 classes

ההשערה

ייצוג היררכי שמבחין בין שורות שנוספו, נמחקו ונשמרו ישפר את זיהוי החוסר.





CC2Vec PatchNet DeepJIT CodeReviewer

# מהיסטוריית קוד לניסוי מבוקר



כל שינוי נשמר ברמת קובץ, והזוג המקורי והסינתטי נשאר באותה חלוקה.

Dataset Overview



5,903

raw candidates

2,843

weak-labeled real

5,500

after synthetic holes

train 3,873    validation 830    test 797

## SYNTHETIC HOLE

```
+ if (req_i) begin  
+   state_d = BUSY;  
  
+ end
```

## COMPLETE

```
+ if (req_i) begin  
+   state_d = BUSY;  
+   valid_d = 1'b1;  
+ end
```



drop\_added\_line

82.2%

of test synthetic examples

# השוואת ארבע משפחות מודלים

4

**Hierarchical  
Transformer**

line encoder + diff  
structure

3

**BiGRU**

flat sequence encoder

2

**MLP**

pooled token  
embeddings


1

**TF-IDF + Logistic  
Regression**

sparse lexical features

**Multi-task head**


ייצוג משותף לשתי המשימות, עם פלט נפרד לכל משימה.



ADD DEL  
CONTEXT

line-type embedding

מידע מפורש על תפקיד כל שורה בתוך השינוי.

**0.4197**

test Macro-F1

**TF-IDF**

קו הבסיס השיג את התוצאה הטובה ביותר. האות הלקסיקלי הספיק כדי לעקוף את המודלים העמוקים.

**refactor\_cleanup**

# בדיקת בקרה חושפת דליפה

message-only  
model




weak label

commit message


0.9855

Macro-F1

המדד כמעט משחזר את מנגנון התיוג, ולכן אינו הוכחה להבנת קוד טהורה.




Hole Confusion Matrices (Row-Normalized)





Ablation Results on the Full Experiment



# מה המודל עדיין לא הוכיח

Synthetic Coverage


רוב הדוגמאות נוצרו מהסרת שורה שנוספה.

Rare Mutations

יש מעט דוגמאות לשינויים סמנטיים עדינים.

External Validity

לא בוצעה הערכה סופית על פרויקט חיצוני.



נדרש סט בדיקה ידני של חוסרים אמיתיים.

0.4197

Intent Macro-F1

ייצוג מבנה השינוי חשוב יותר מנפח המודל.

1

0.6029

hole F1

מידע מפורש על סוג השורה מצמצם התראות שווא ומשפר זיהוי חוסר.



2


0.7352

hole AUROC


מקור התוויות חייב להיות עצמאי ממנגנון התיוג.

3







Improved Weak Labeling



Hardware-aware Features



Cross-project Study



Medium-scale studies

המספרים אינם בני השוואה ישירה לניסוי המלא. הם מצביעים על שיפור כיסוי התיוג, ערך של מאפייני חומרה ופער בין פרויקטים.