

DiffIntent-RTL

זיהוי מטרת שינוי וחוסרים פונקציונליים
בקוד

RTL

Deep Learning Project

קורן הנס ונועה סבג

15 min

Final Presentation

```
@@ always_ff @(posedge clk_i) @@  
- if (!rst_ni) state_q <= IDLE;  
+ if (!rst_ni) state_q <= IDLE;  
+ else if (req_i) begin  
+   state_q <= BUSY;  
+   valid_o <= 1'b1;  
+ end
```

What if the final assignment is missing?

השינוי עדיין יכול להיות תקין
תחבירית
אבל ההתנהגות הרצויה אינה
שלמה

מפתח אנושי קורא הקשר, מבנה והבדלים
בין שורות. המודל חייב לקבל את אותם
רמזים.

□ Code Review □ מפתח אנושי בתהליך
קורא יחד את ההקשר, המבנה וההבדל בין
השורות.

שתי שאלות מחקר, אובייקט למידה אחד

Completeness

האם השינוי נראה שלם?

binary task

Intent

איזו מטרה עומדת מאחורי השינוי?


4 classes

ההשערה

ייצוג היררכי שמבחין בין שורות שנוספו, נמחקו ונשמרו ישפר את זיהוי החוסר.





CC2Vec PatchNet DeepJIT CodeReviewer

מהיסטוריית קוד לניסוי מבוקר



כל שינוי נשמר ברמת קובץ, והזוג המקורי והסינתטי נשאר באותה חלוקה.

Dataset Overview



5,903

raw candidates

2,843

weak-labeled real

5,500

after synthetic holes

train 3,873 validation 830 test 797

SYNTHETIC HOLE

```
+ if (req_i) begin  
+   state_d = BUSY;  
  
+ end
```

COMPLETE

```
+ if (req_i) begin  
+   state_d = BUSY;  
+   valid_d = 1'b1;  
+ end
```



drop_added_line

82.2%

of test synthetic examples

השוואת ארבע משפחות מודלים

4

Hierarchical Transformer

line encoder + diff structure

3

BiGRU

flat sequence encoder

2

MLP


pooled token embeddings

1


TF-IDF + Logistic Regression

sparse lexical features

אותו ייצוג משמש לשתי המשימות באמצעות □ Multi-task head □ וכל משימה מקבלת פלט נפרד.



הייצוג $\square$ line-type embedding $\square$ מוסיף מידע מפורש על תפקיד כל שורה בתוך השינוי.


**0.4197**

test Macro-F1

קו הבסיס □ TF-IDF □ השיג
את התוצאה הטובה ביותר.
האות הלקסיקלי הספיק כדי
לעקוף את המודלים העמוקים.

refactor_cleanup




בדיקת בקרה חושפת דליפה




0.9855

Macro-F1

המדד כמעט משחזר את מנגנון התיוג, ולכן אינו הוכחה להבנת קוד טהורה.




Hole Confusion Matrices (Row-Normalized)





Ablation Results on the Full Experiment



Synthetic Coverage

רוב הדוגמאות נוצרו מהסרת שורה שנוספה.

Rare Mutations

יש מעט דוגמאות לשינויים סמנטיים עדינים.

External Validity

לא בוצעה הערכה סופית על פרויקט חיצוני.

82.2%**drop_added_line**

mutation distribution

**נדרש סט בדיקה ידני של
חוסרים אמיתיים.**

0.4197

Intent Macro-F1

0.6029

hole F1

0.7352



hole AUROC


1 ייצוג מבנה השינוי חשוב יותר מנפח המודל.

2 מידע מפורש על סוג השורה מצמצם התראות שווא ומשפר זיהוי חוסר.


3 מקור התוויות חייב להיות עצמאי. אין להעריך הבנת קוד לפי ☐ commit message ☐

שאלות?







Improved Weak Labeling



Hardware-aware Features



Cross-project Study



Medium-scale studies

המספרים אינם בני השוואה ישירה לניסוי המלא. הם מצביעים על שיפור כיסוי התיוג, ערך של מאפייני חומרה ופער בין פרויקטים.