

DiffIntent-RTL

זיהוי מטרת שינוי וחוסרים פונקציונליים
בקוד

RTL

Deep Learning Project

קורן חנס ונועה סבג

```
@@ always_ff @(posedge clk_i) @@  
- if (!rst_ni) state_q <= IDLE;  
+ if (!rst_ni) state_q <= IDLE;  
+ else if (req_i) begin  
+   state_q <= BUSY;  
+   valid_o <= 1'b1;  
+ end
```

What if the final assignment is missing?

השינוי עדיין יכול להיות תקין
תחבירית
אבל ההתנהגות הרצויה אינה
שלמה

מפתח אנושי קורא הקשר, מבנה והבדלים
בין שורות. המודל חייב לקבל את אותם
רמזים.

מפתח אנושי בתהליך **Code** **Review** **PDI**
קורא יחד את ההקשר, המבנה
וההבדל בין השורות.

Completeness

האם השינוי נראה שלם?

binary task

Intent

איזו מטרה עומדת מאחורי השינוי?


4 classes

ההשערה

ייצוג היררכי שמבחין בין שורות שנוספו, נמחקו ונשמרו ישפר את זיהוי החוסר.





CC2Vec PatchNet DeepJIT CodeReviewer

מהיסטוריית קוד לניסוי מבוקר



כל שינוי נשמר ברמת קובץ, והזוג המקורי והסינתטי נשאר באותה חלוקה.

Dataset Overview



5,903

raw candidates

2,843

weak-labeled real

5,500

after synthetic holes

train 3,873 validation 830 test 797

SYNTHETIC HOLE

```
+ if (req_i) begin  
+   state_d = BUSY;  
  
+ end
```

COMPLETE

```
+ if (req_i) begin  
+   state_d = BUSY;  
+   valid_d = 1'b1;  
+ end
```



drop_added_line

82.2%

of test synthetic examples

השוואת ארבע משפחות מודלים

4

**Hierarchical
Transformer**

line encoder + diff
structure

3

BiGRU

flat sequence encoder

2

MLP


pooled token
embeddings

1


**TF-IDF + Logistic
Regression**

sparse lexical features

אותו ייצוג משמש לשתי המשימות באמצעות Multi-task head וכל משימה מקבלת פלט נפרד.




הייצוג line-type embedding מוסיף מידע מפורש על תפקיד כל שורה בתוך השינוי.

**0.4197**

test Macro-F1

קו הבסיס TF-IDF השיג את התוצאה הטובה ביותר. האות הלקסיקלי הספיק כדי לעקוף את המודלים העמוקים.

refactor_cleanup



מודל מבוסס 18 מאפייני חומרה (reset, parameter, שורות
עם Random Forest (+/-).

באימות צולב 0.525 ± 0.114 , שקול ל - TF-IDF (0.544)
אך מובן לאדם.

```
review(diff) →  
✓ hole score 0.21 (שלם)  
⚠ hole score 0.52 (ייתכן חסר)
```

כלי שמקבל שינוי ומחזיר כוונה משוערת + אזהרת שלמות

בדיקת בקרה חושפת דליפה

message-only
model



weak label

commit message

0.9855

Macro-F1

המדד כמעט משחזר את מנגנון התיוג, ולכן אינו הוכחה להבנת קוד טהורה.



29% → 16%

שיעור פסילה — OpenTitan

53% → 25%

שיעור פסילה — Caliptra

- המתייג כויל ל- OpenTitan ולא הכליל היטב לפרויקט שני.
- הרחבת מילות המפתח צמצמה את הפער בין הפרויקטים מ-24 ל-9 נקודות.
- פרופיל השינויים מתהפך: ב- OpenTitan פיצ'רים, ב- Caliptra תיקוני באג.

172 → 81

false positives


0.7352

AUROC

0.6029


hole F1

Hole Confusion Matrices (Row-Normalized)



-0.1305 Δ hole F1**-0.1058** Δ AUROC

Ablation Results on the Full Experiment



Synthetic Coverage

רוב הדוגמאות נוצרו מהסרת שורה שנוספה.

Rare Mutations

יש מעט דוגמאות לשינויים סמנטיים עדינים.

External Validity

לא בוצעה הערכה סופית על פרויקט חיצוני.

82.2%**drop_added_line**

mutation distribution

**נדרש סט בדיקה ידני של
חוסרים אמיתיים.**

0.4197

Intent Macro-F1

1 ייצוג מבנה השינוי חשוב יותר מנפח המודל.

0.6029



hole F1


2 מידע מפורש על סוג השורה מצמצם התראות שווא ומשפר זיהוי חוסר.

0.7352


hole AUROC

3 מקור התוויות חייב להיות עצמאי. אין להעריך הבנת קוד לפי commit message







Improved Weak Labeling



Hardware-aware Features



Cross-project Study



Medium-scale studies

המספרים אינם בני השוואה ישירה לניסוי המלא. הם מצביעים על שיפור כיסוי התיוג, ערך של מאפייני חומרה ופער בין פרויקטים.