DiffIntent-RTL

זיהוי מטרת שינוי וחוסרים פונקציונליים בקוד RTL

קורן חנס ונועה סבג

Deep Learning Project

חוסר גדול מסתתר בשינוי קטן

```
@@ always_ff @(posedge clk_i) @@
- if (!rst_ni) state_q <= IDLE;
+ if (!rst_ni) state_q <= IDLE;
+ else if (req_i) begin
+   state_q <= BUSY;
+   valid_o <= 1'b1;
+ end
```

What if the final assignment is missing?

השינוי עדיין יכול להיות תקין תחבירית
אבל ההתנהגות הרצויה אינה שלמה

מפתח אנושי בתהליך Code Review בוחן יחד את ההקשר, המבנה וההבדל בין השורות.
המודל חייב לקבל את אותם רמזים.

שתי שאלות מחקר, אובייקט למידה אחד

Intent

איזו מטרה עומדת מאחורי השינוי?

4 classes

Completeness

האם השינוי נראה שלם?

binary task

ההשערה

ייצוג היררכי שמבחין בין שורות שנוספו, נמחקו ונשמרו ישפר את זיהוי החוסר.

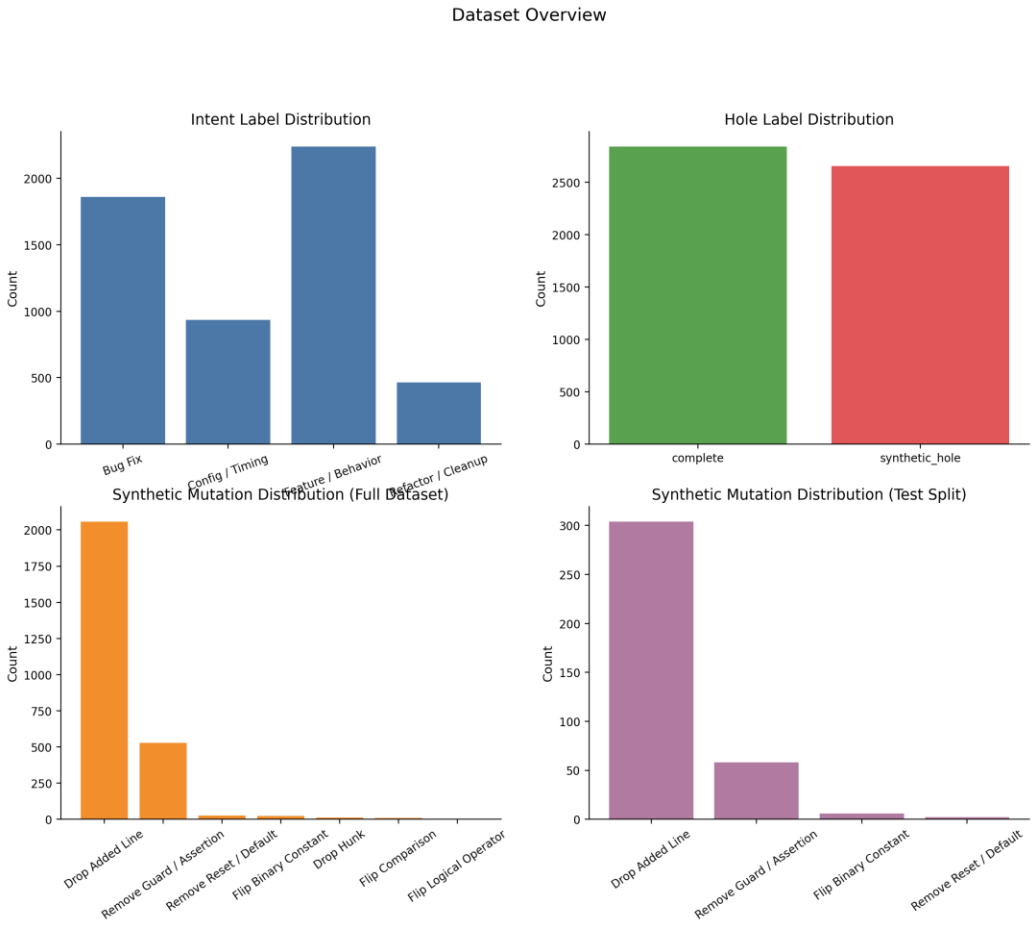
CC2Vec PatchNet DeepJIT CodeReviewer

מהיסטוריית קוד לניסוי מבוקר



כל שינוי נשמר ברמת קובץ, והזוג המקורי והסינתטי נשאר באותה חלוקה.

מערך הנתונים: כרונולוגי, מאוזן בזוגות



5,903

raw candidates

2,843

weak-labeled real

5,500

after synthetic holes

train 3,873 validation 830 test 797

יצירת חוסרים סינתטיים בתוך אזור השינוי

SYNTHETIC HOLE

```
+ if (req_i) begin
+   state_d = BUSY;

+ end
```

COMPLETE

```
+ if (req_i) begin
+   state_d = BUSY;
+   valid_d = 1'b1;
+ end
```

drop_added_line

82.2%

of test synthetic examples

השוואת ארבע משפחות מודלים

4

Hierarchical Transformer

line encoder + diff structure

3

BiGRU

flat sequence encoder

2

MLP

pooled token embeddings

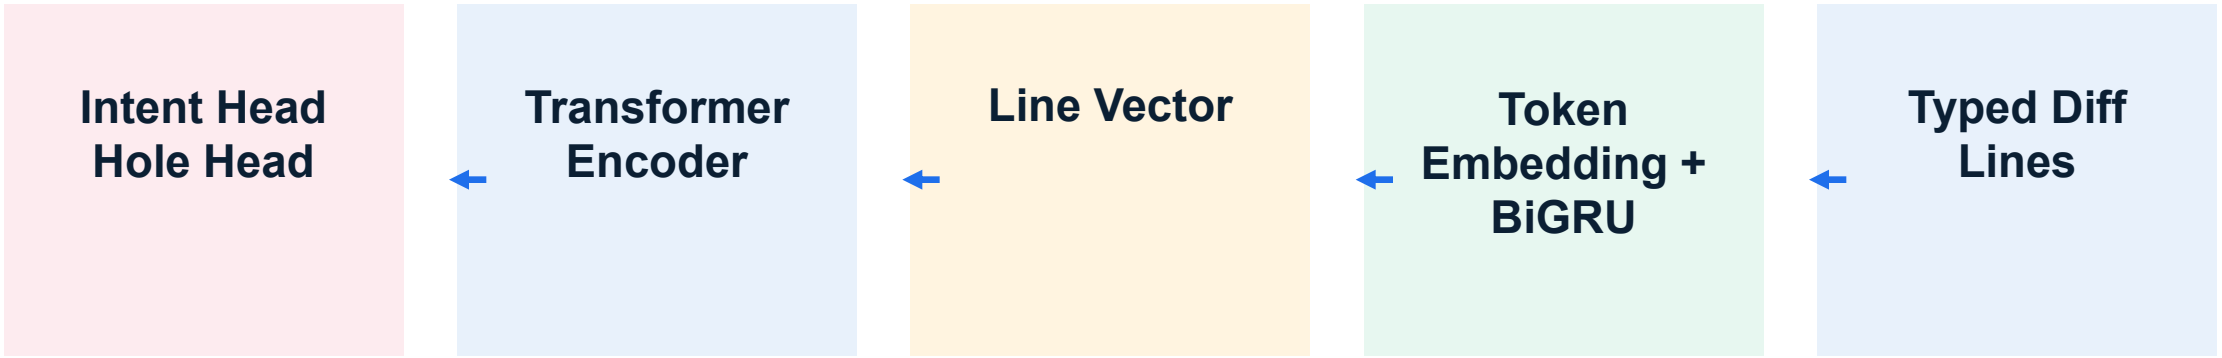
1

TF-IDF + Logistic Regression

sparse lexical features

אותו ייצוג משמש לשתי המשימות באמצעות Multi-task head וכל משימה מקבלת פלט נפרד.

הארכיטקטורה ההיררכית



הייצוג line-type embedding מוסיף מידע מפורש על תפקיד כל שורה בתוך השינוי.

סיווג המטרה: המודל הפשוט ניצח



0.4197

test Macro-F1

קו הבסיס TF-IDF השיג את התוצאה הטובה ביותר. האות הלקסיקלי הספיק כדי לעקוף את המודלים העמוקים.

refactor_cleanup

בדיקת בקרה חושפת דליפה

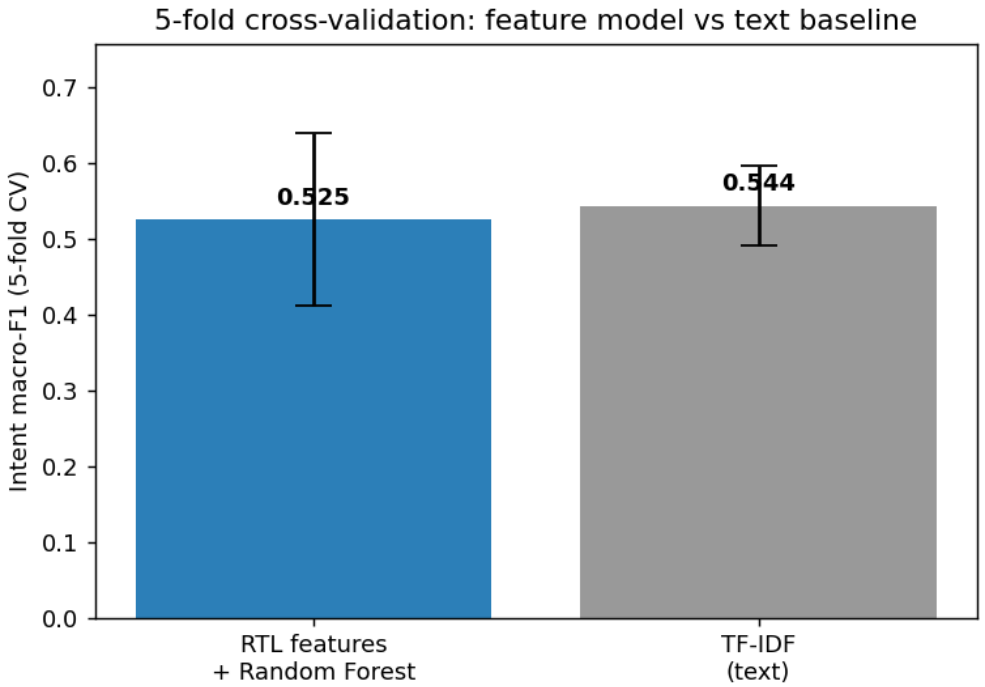
commit message ← weak label ← message-only model

0.9855

Macro-F1

המדד כמעט משחזר את מנגנון התיוג, ולכן אינו הוכחה להבנת קוד טהורה.

מודל מאפייני-חומרה ועוזר לסקירת קוד

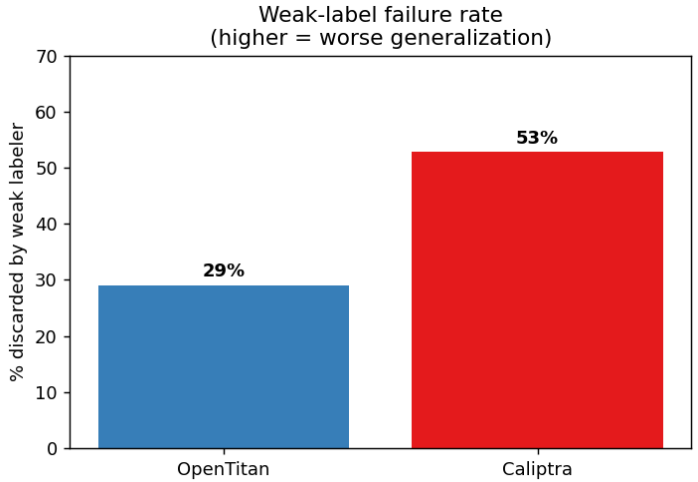


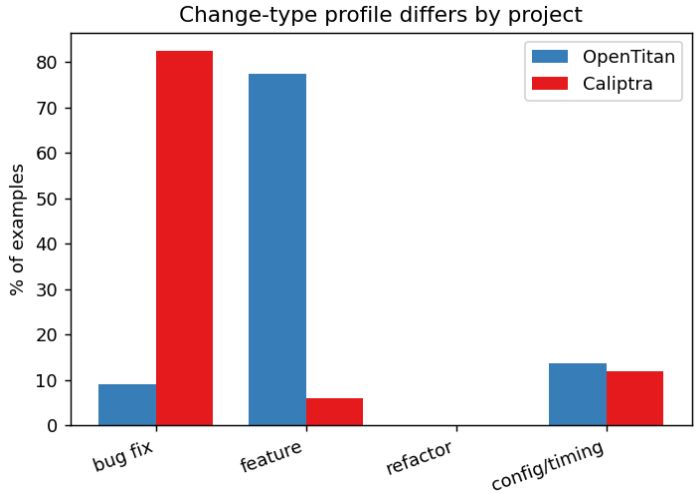
מודל מבוסס 18 מאפייני חומרה (reset, parameter, שורות –/+) עם Random Forest.
באימות צולב 0.525 ± 0.114, שקול ל- TF-IDF (0.544) אך מובן לאדם.

```
review(diff)  →
✓   שלם(hole score 0.21)
⚠   חסר יתכן'(hole score 0.52)
```

כלי שמקבל שינוי ומחזיר כוונה משוערת + אזהרת שלמות

מחקרי הרחבה: הכללה ושיפור התיוג





29% → 16%

שיעור פסילה— OpenTitan

53% → 25%

שיעור פסילה— Caliptra

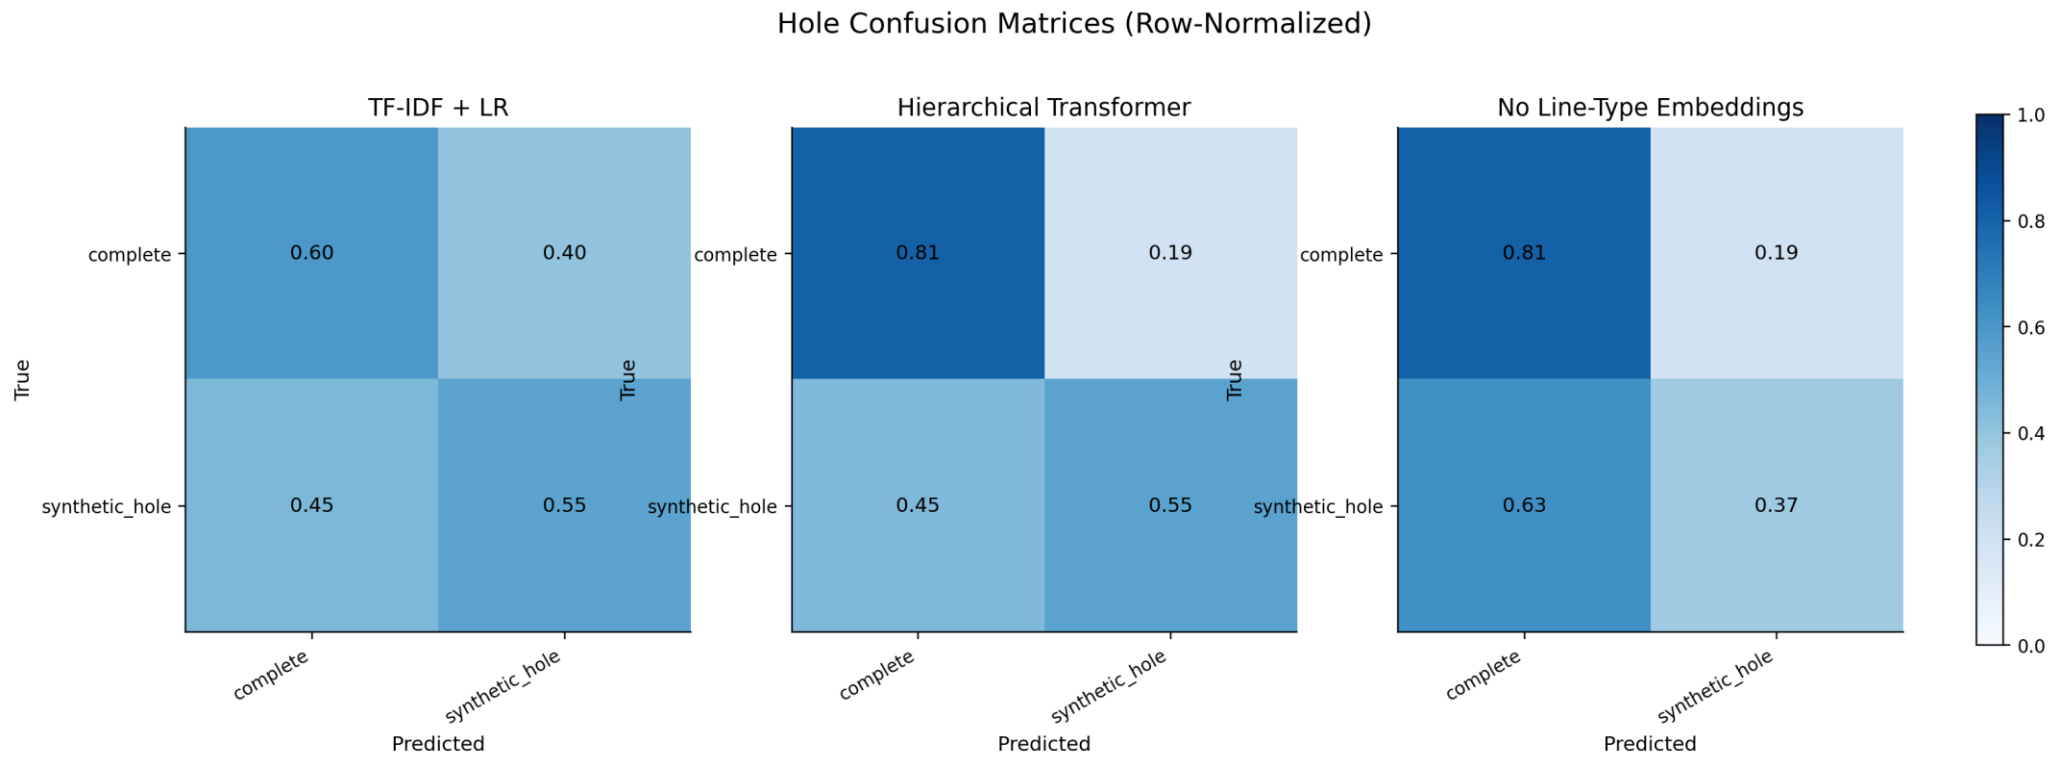
- **המתייג כויל ל- OpenTitan ולא הכליל היטב לפרויקט שני.**
- **הרחבת מילות המפתח צמצמה את הפער בין הפרויקטים מ-24 ל-9 נקודות.**
- **פרופיל השינויים מתהפך: ב- OpenTitan פיצ'רים, ב- Caliptra תיקוני באג.**

זיהוי חוסר: המבנה ההיררכי ניצח

172 → 81
false positives

0.7352
AUROC

0.6029
hole F1



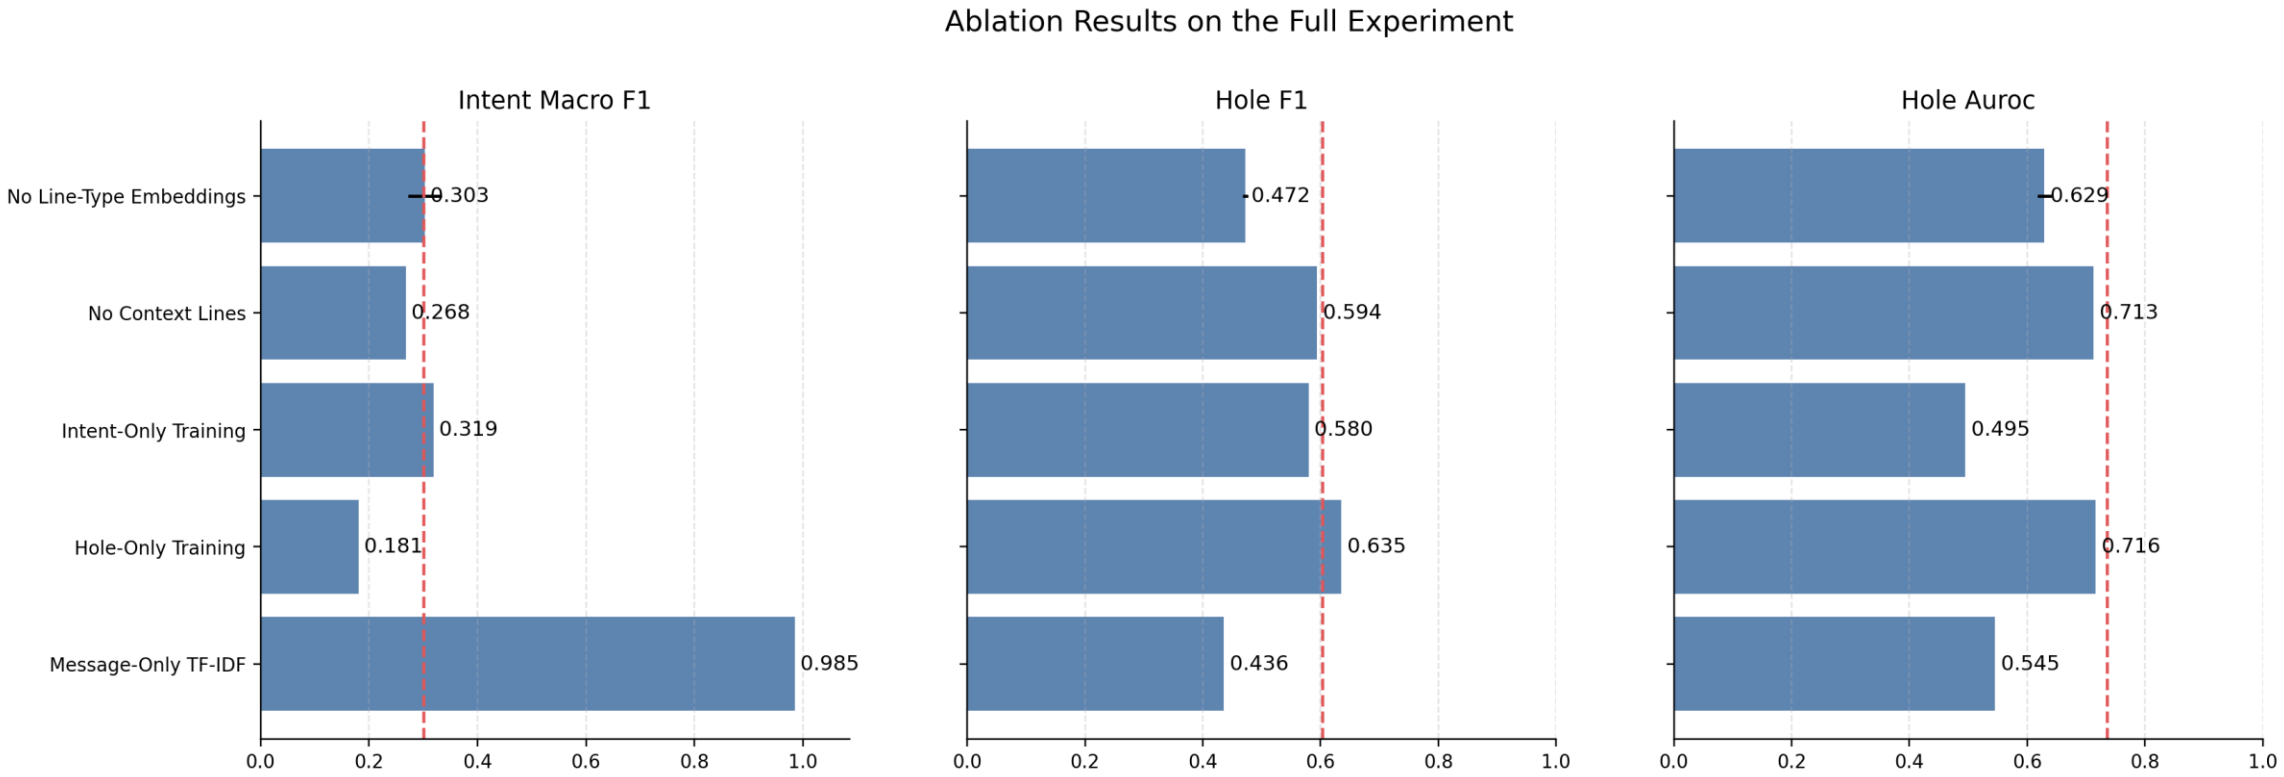
מידע על סוג השורה הוא רכיב מהותי

−0.1305

Δ hole F1

−0.1058

Δ AUROC



מה המודל עדיין לא הוכיח

Synthetic Coverage

רוב הדוגמאות נוצרו מהסרת שורה שנוספה.

Rare Mutations

יש מעט דוגמאות לשינויים סמנטיים עדינים.

External Validity

לא בוצעה הערכה סופית על פרויקט חיצוני.

82.2%

drop_added_line



mutation distribution

נדרש סט בדיקה ידני של חוסרים אמיתיים.

מסקנות ושאלות

0.4197

Intent Macro-F1

0.6029

hole F1

0.7352

hole AUROC

1 ייצוג מבנה השינוי חשוב יותר מנפח המודל.

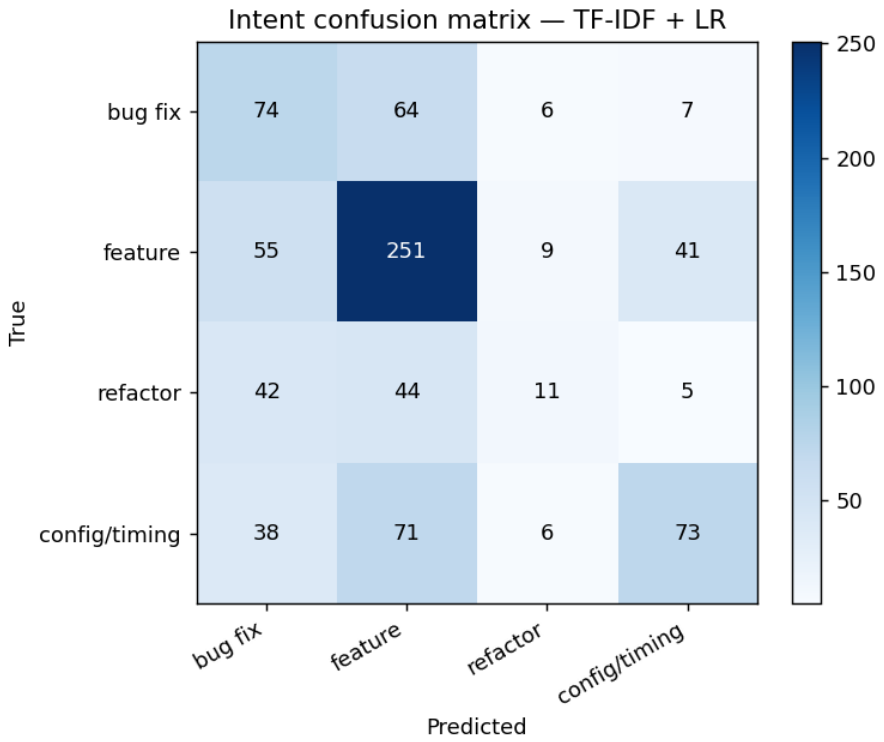
2 מידע מפורש על סוג השורה מצמצם התראות שווא ומשפר זיהוי חוסר.

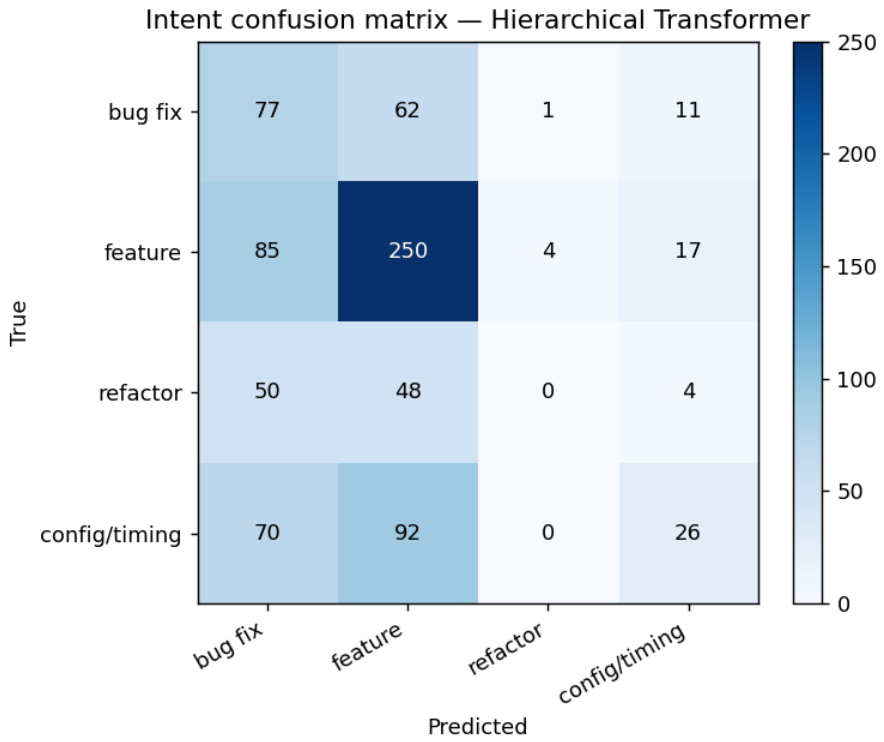
3 מקור התוויות חייב להיות עצמאי. אין להעריך הבנת קוד לפי commit message

שאלות?

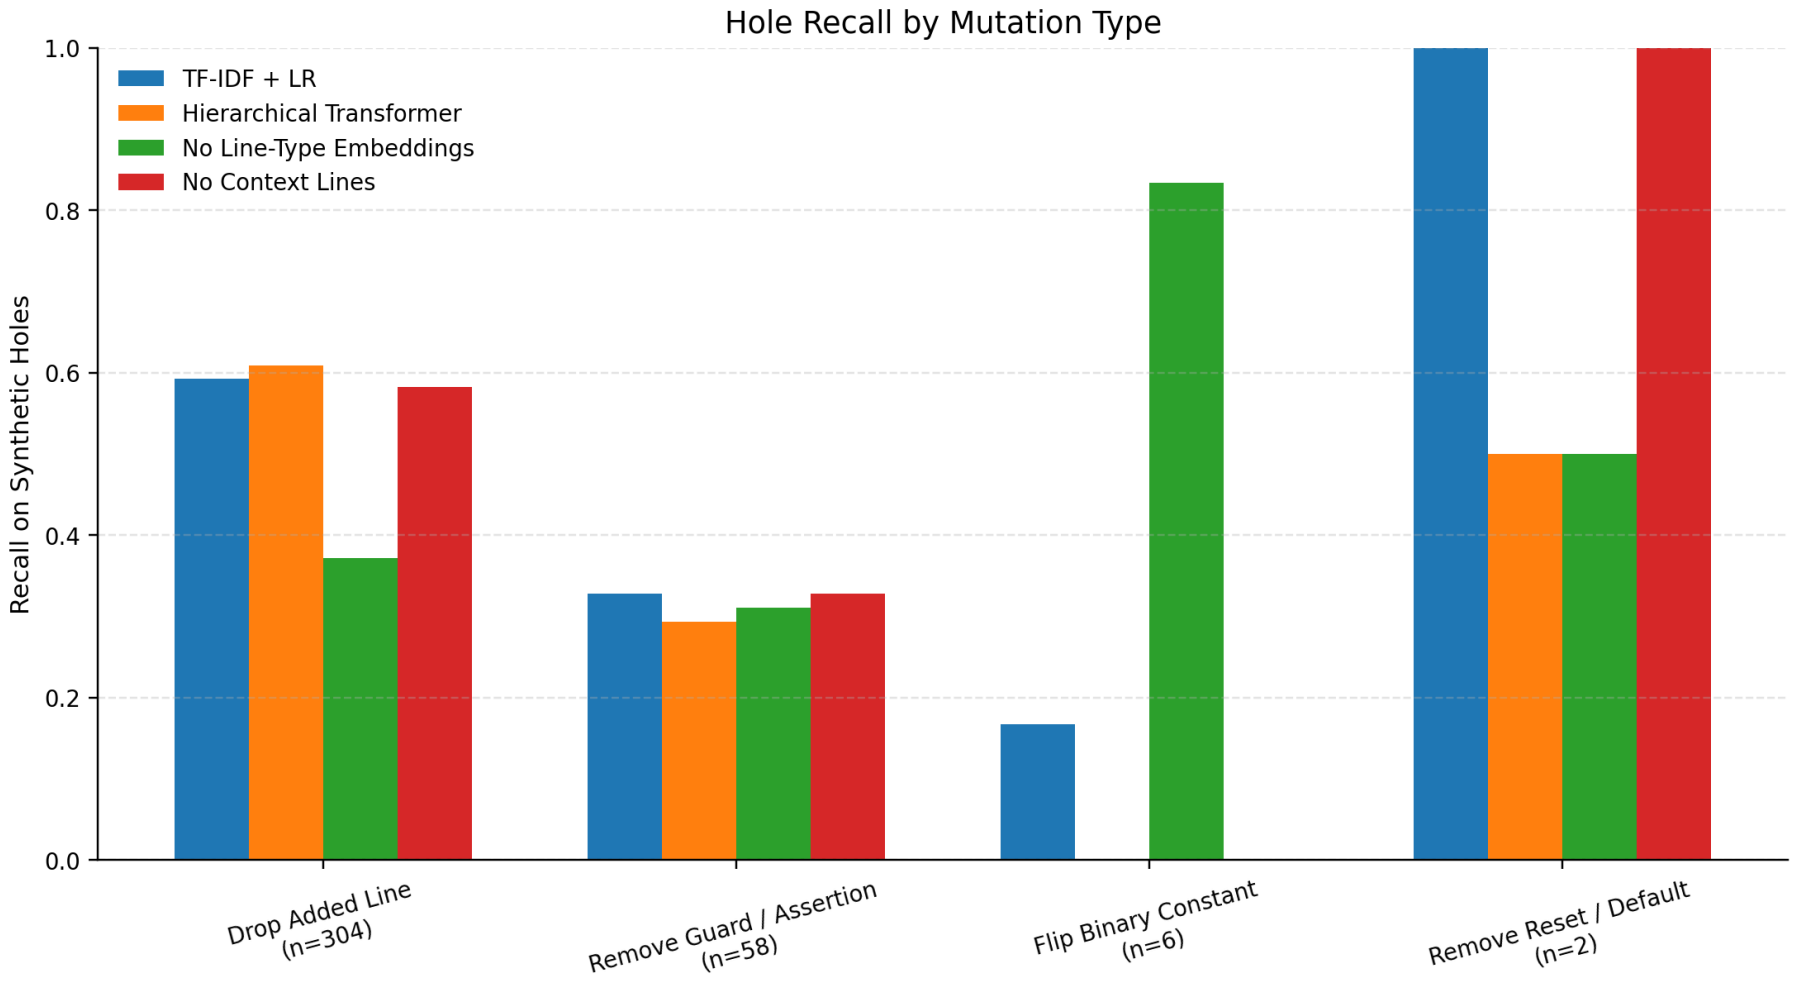
github.com/korrenhannes/diffintent-rtl

גיבוי: מטריצות בלבול



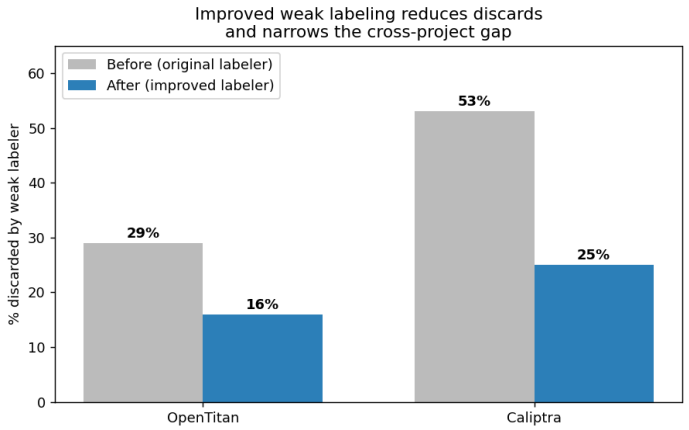


גיבוי: ביצועים לפי סוג שינוי

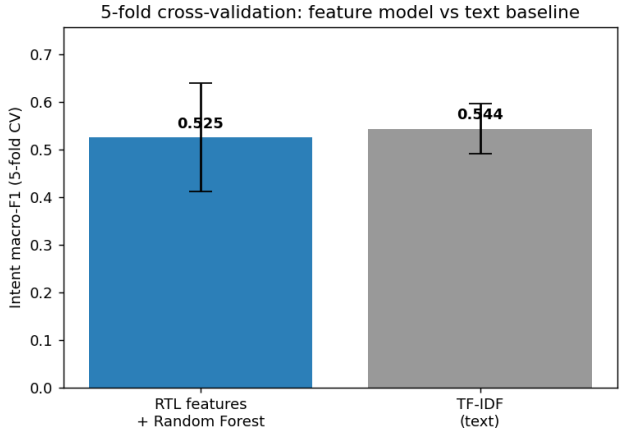


גיבוי: מחקרי הרחבה

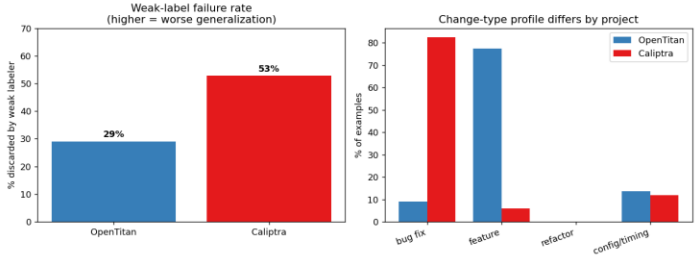
Improved Weak Labeling



Hardware-aware Features



Cross-project Study



Medium-scale studies

המספרים אינם בני השוואה ישירה לניסוי המלא. הם מצביעים על שיפור כיסוי התיוג, ערך של מאפייני חומרה ופער בין פרויקטים.