

## זיהוי כוונת שינוי ומימוש חסר בקוד חומרה באמצעות DiffIntent RTL

קורן חנס ונועה סבג  
פרויקט מסכם בקורס למידה עמוקה  
עיבוד שפה טבעית לקוד מקור באמצעות PyTorch

### תקציר

מאגרי קוד חומרה המתוארים ב-RTL מתפתחים באמצעות אלפי שינויים קטנים. שורה חסרה באתחול, בתנאי הגנה או ב-assertion עלולה ליצור תקלה שקשה לזהות בסקירת קוד. בפרויקט בחנו שתי משימות על שינוי SystemVerilog מהיסטוריית OpenTitan: סיווג כוונת השינוי לארבע קטגוריות, וזיהוי שינוי חלקי שנוצר בהשמטה מבוקרת של קוד. בנינו מערך נתונים של 5,500 דוגמאות והשוונו מודל TF-IDF עם רגרסיה לוגיסטית לשלושה מודלים עצביים שמומשו ב-PyTorch, כאשר המודל ההיררכי מייצג בנפרד שורות שנוספו, נמחקו או נשמרו. TF-IDF השיג Macro-F1 של 0.4197 בסיווג הכוונה, והמודל ההיררכי הוביל בזיהוי מימוש חסר עם F1 של 0.6029 ו-AUROC של 0.7352. הסרת הטמעת סוג השורה הורידה את F1 ל-0.4724. עם זאת, מודל המבוסס רק על הודעת השינוי הגיע ל-Macro-F1 של 0.9855, ממצא החושף תלות חזקה בין הודעות השינוי לבין התוויות החלשות. המסקנה היא שמבנה השינוי מועיל לזיהוי שלמות, אך הערכת כוונה אמינה דורשת תוויות שאינן נגזרות מהודעות השינוי.

### 1. מבוא ומוטיבציה

סקירת שינויי RTL שונה מסיווג טקסט רגיל. הקלט הוא code diff, כלומר תיאור טקסטואלי של ההבדלים בין שתי גרסאות, ומשמעותו תלויה גם באסימוני הקוד וגם בתפקיד המבני של כל שורה: תוספת, מחיקה או הקשר שלא השתנה. הרצאות הקורס על נתונים מובנים מדגישות שהארכיטקטורה צריכה להטמיע הטיה אינדוקטיבית, כלומר הנחה מוקדמת על היחסים החשובים בקלט [10]. בפרויקט, הנחה זו מתבטאת בהיררכיה של אסימונים בתוך שורות ושל שורות בתוך שינוי. שינוי קצר עשוי להיות תקין תחבירית ובכל זאת חסר מבחינה פונקציונלית, ולכן המודל מיועד לתעדף שינויים חשודים לסקירה. הוא אינו מחליף סימולציה, המריצה תרחשי קלט, או אימות פורמלי, הבודק תכונות מתמטיות בכל המצבים המתוארים במודל. הפלט הוא ציון סיכון סטטיסטי המסייע לבדוק אנושי ואינו הוכחה לנכונות החומרה.

#### 1.1 שאלות המחקר

- האם ניתן לסווג מתוך הפרש הקוד את כוונת השינוי: תיקון תקלה, שינוי תכונה או התנהגות, ארגון מחדש או ניקוי קוד, ושינוי תצורה או תזמון?
- האם ניתן להבחין בין שינוי שלם לבין מימוש חסר מלאכותי שנוצר מתוך שינוי אמיתי?
- האם ייצוג היררכי של הפרש הקוד וסוגי השורות משפר ביצועים לעומת ייצוגים לקסיקליים ורצפים שטוחים?

### 2. בסיס תאורטי ועבודות קשורות

#### 2.1 מסגרת תאורטית

הפרויקט נשען על מסגרת הלמידה המונחית שנלמדה בקורס. כל מודל מקבל ייצוג של שינוי  $x$  ומפיק הסתברויות למחלקות. ההשוואה בין המודלים בוחנת שתי שאלות נפרדות: איזה מידע נכלל בייצוג, ואיזה מבנה חישובי מתאים ליחסים שבתוכו. המעבר מטקסט טבעי לקוד אינו משנה את עקרונות היסוד, אך הוא משנה את ההטיה האינדוקטיבית הנדרשת. הקורס מציג היררכיה ומקומיות כדוגמאות להתאמת מבנה המודל למבנה הנתונים [10]. כאן המקומיות מתקיימת בתוך שורת קוד, וההיררכיה מחברת בין אסימונים, שורות ומקטעי שינוי. עקרונות עיבוד השפה הטבעית וה-Transformers [11,12] מופיעים בהמשך בתוך קדם-העיבוד, הארכיטקטורה וניסויי האבלציה, ולא כרשימת מונחים נפרדת. הערכת המודל מבחינה בין התאמה לנתוני האימון לבין הכללה לדוגמאות שלא נראו. בהתאם לעקרונות הרגולריזציה והעצירה המוקדמת שנלמדו בקורס [9], השתמשנו בקבוצת אימות, ב-dropout וב-weight decay, והחלוקה הכרונולוגית נועדה לשקף תחזית של שינויים עתידיים.

#### 2.2 עבודות קשורות

מחקרים קודמים מראים כי ייצוג של שינוי קוד צריך לשמר את הפעולה שבוצעה ולא רק את תמונת המצב הסופית. CC2Vec לומד ייצוג של תיקון מתוך הקוד שנוסף, הקוד שנמחק והודעת השינוי [2]. PatchNet מארגן תיקון כמבנה היררכי [3], ו-DeepJIT משלב את הודעת השינוי עם הקוד לצורך חיזוי תקלות [4]. CodeReviewer מרחיב כיוון זה באמצעות קדם-אימון למשימות סקירת קוד [5]. הפרויקט מאמץ את עקרון הייצוג המבני, אך מתאים אותו ל-RTL: סוג השורה מיוצג במפורש, והמקודד משותף לשני יעדים, כוונת השינוי ושלמות המימוש. אימון כזה נקרא למידה רב-משימתית, משום שאותם פרמטרים פנימיים מתעדכנים משתי פונקציות מטרה.

### 3. מערך הנתונים

#### 3.1 כרייה וסינון

הדוגמאות נכרו אוטומטית מהיסטוריית OpenTitan [1], פרויקט קוד פתוח לחומרת אבטחה. נשמרו שינויים בקובצי Verilog, והוחרגו תיקיות DV, tests, vendor, third\_party, generated, build ו-out, וכן שינויי מיזוג, פעולות revert, הודעות ריקות והפרשים גדולים מדי. יחידת הדוגמה היא שינוי בקובץ יחיד.

### 3.2 תיוג כוונה

מאחר שבמאגר אין תוויות ידניות לכוונת השינוי, השתמשנו ב- weak labeling - תיוג אוטומטי לפי כללים, זול להפקה אך רועש. ארבע התוויות הן bug\_fix לתיקון תקלה, feature\_or\_behavior\_change לשינוי תכונה או התנהגות, refactor\_cleanup לארגון מחדש או ניקוי קוד, ו-configuration\_timing לשינוי תצורה או תזמון. לדוגמה, fix או bug מצביעות על bug\_fix, ואילו clock, אות התזמון המחזורי של המעגל, reset, אות המחזיר את המעגל למצב התחלתי, או parameter, קבוע תצורה בזמן בניית החומרה, מצביעות על configuration\_timing. דוגמה ללא התאמה הוסרה, וכך גם דוגמה שבה כמה קטגוריות קיבלו ציון מרבי. כך הוסרו 2,713 דוגמאות ללא התאמה ו-347 דוגמאות עמומות. מגבלת השיטה מהותית: התוויות נגזרות מהודעת השינוי ולכן אינה בלתי תלויה באחד ממקורות הקלט האפשריים.

### 3.3 יצירת דוגמאות של מימוש חסר

כל שינוי אמיתי סומן כדוגמה שלמה. לאחר מכן נוצרה לכל היותר דוגמה חסרה אחת באמצעות מוטציה מלאכותית - שינוי מבוקר בקוד שנועד לדמות טעות מימוש. המוטציה הראשונה שניתן היה להחיל נבחרה מתוך: הסרת guard, הסרת assertion, הסרת השמת reset או default, השמטת שורה שנוספה, השמטת hunk, החלפת אופרטור, או היפוך קבוע בינארי. הדוגמה המקורית והמוטנטית חולקות pair\_id ונשמרות באותה קבוצה, כדי שהמודל לא יראה באימון את המקור של דוגמת בדיקה. סדר העדיפויות מסביר מדוע drop\_added\_line נפוצה הרבה יותר ממוטציות עדינות. מערך הנתונים כולל 5,903 דוגמאות גולמיות, מתוכן 2,843 שינויים אמיתיים מתויגים, ולאחר יצירת מימושים חסרים התקבלו 5,500 דוגמאות. חלוקת אימון / אימות / בדיקה היא 3,873 / 830 / 797, היחס בין שינוי שלם למימוש חסר מלאכותי הוא 2,843 / 2,657, והאורך הממוצע של הפרש הקוד הוא 37.678 שורות מנומלות.

### 3.4 התפלגות וקדם-עיבוד

התפלגות הכוונות אינה מאוזנת: feature\_or\_behavior\_change מהווה 40.7%, configuration\_timing 17.0%, bug\_fix 33.8%, ו-refactor\_cleanup רק 8.5%. תוויות השלמות כמעט מאוזנות. הפרש הקוד מומר לשורות מסומנות (FILE, HUNK, CTX, DEL, ADD). בהתאם לחומר הקורס על עיבוד שפה טבעית tokenization [11], מותאם ל-SystemVerilog שומר מזהים, מילות מפתח, ערכים, הוראות macro ואופרטורים. האורך מוגבל ל-128 שורות ו-64 אסימונים בשורה, ובקיצוץ נשמרות תחילה השורות שהשתנו וההקשר הקרוב. אוצר המילים נבנה מקבוצת האימון בלבד.

### 3.5 חלוקת הנתונים והערכת דליפה

הדוגמאות מוינו כרונולוגית לפי תאריך השינוי וחולקו ביחס 15/15/70 לקבוצות אימון, אימות ובדיקה. קבוצת האימון משמשת להתאמת הפרמטרים, קבוצת האימות לבחירת המודל ונקודת העצירה, וקבוצת הבדיקה להערכה סופית בלבד. כל צמד של דוגמת מקור ומוטציה נשמר באותה קבוצה. כך נמנעה דליפה ישירה, מצב שבו מידע מדוגמת בדיקה משפיע על האימון ומנפח את המדדים. החלוקה אינה מופרדת לפי קבצים: אותו קובץ RTL עשוי להופיע בשינויים שונים ובקבוצות שונות. לכן התוצאות מודדות הכללה קדימה בזמן בתוך OpenTitan, ולא הכללה לקבצים או לפרויקטים שלא נראו באימון.

## 4. מודלים ושיטת האימון

### 4.1 המודלים שנבדקו

מודל הבסיס משתמש ב-TF-IDF עם רגרסיה לוגיסטית [7]. הייצוג כולל מילים ו-character n-gram. הלוכדים גם חלקי מזהים ואופרטורים. MLP היא רשת הזנה קדימה רב-שכבתית [7]. BiGRU היא רשת חוזרת דו-כיוונית המרחיבה את מודלי הרצף שנלמדו בהרצאת עיבוד השפה הטבעית [11]. המודל ההיררכי מקודד תחילה כל שורה ולאחר מכן את רצף השורות. משקלי מחלקות מגדילים את תרומת המחלקות הנדירות לפונקציית ההפסד, ו-dropout מפחיתה התאמת יתר [9].

טבלה 1: ארבעת המודלים המרכזיים.

| מודל                     | ייצוג                                 | הגדרות עיקריות                            |
|--------------------------|---------------------------------------|-------------------------------------------|
| TF-IDF ורגרסיה לוגיסטית  | מילים ו-char n-grams                  | עד 50 אלף מאפיינים ומשקלי מחלקות מאוזנים  |
| MLP                      | הטמעת אסימונים ומיצוע                 | הטמעה 128, שכבה חבויה 256, dropout 0.2    |
| BiGRU                    | רצף אסימונים שטוח                     | שכבה חבויה דו-כיוונית 128 וצבירת קשב      |
| Hierarchical Transformer | אסימונים בתוך שורות ושורות בתוך שינוי | שתי שכבות, ארבעה ראשי קשב והטמעת סוג שורה |

### 4.2 הארכיטקטורה ההיררכית

הארכיטקטורה ההיררכית מיישמת את רצף הרעיונות מהרצאות עיבוד השפה הטבעית ו-Transformers [11,12]. כל אסימון ממופה ל-embedding, מקודד BiGRU קורא כל שורה בשני הכיוונים ומפיק וקטור שורה, ולוקטור מצורפת הטמעת סוג השורה ו-positional encoding. מקודד Transformer מפעיל self-attention בין השורות, ומנגנון צבירת קשב מסכם אותן לייצוג יחיד. לבסוף שני ראשי סיווג החולקים את אותו מקודד מנבאים את הכוונה ואת שלמות המימוש.

איור 1: תרשים זרימה ניתן לעריכה של המודל ההיררכי.

| שלב 1          | שלב 2          | שלב 3          | שלב 4                 | שלב 5          |
|----------------|----------------|----------------|-----------------------|----------------|
| אסימונים בשורה | BiGRU לכל שורה | הטמעת סוג שורה | Transformer בין שורות | שני ראשי סיווג |

### 4.3 פונקציית המטרה

כל ראש מאומן באמצעות [7] cross entropy. באימון רב-משימתי שתי המשימות חולקות את אותו מקודד ומתעדכנות יחד; סכום ההפסדים הוא:

$$L = L_{intent} + \lambda L_{hole}$$

בניסוי המרכזי נקבע  $\lambda = 1$  ולכן לשני ההפסדים משקל שווה. בניסויים החד-משימתיים חושב רק איבר ההפסד המתאים. הנגזרות חושבו ב-[8] backpropagation והפרמטרים עודכנו ב-AdamW עם weight decay לרגולריזציה [9]. קיטום גרדיאנט ב-1.0 מונע עדכונים חריגים, והאימון נעצר לאחר שני סבבים ללא שיפור באימות [9].

### 4.4 פרוטוקול ניסוי

ארבעת המודלים המרכזיים והמודל ללא סוגי שורות אומנו בשלושה אתחולים אקראיים (13, 42, 123) לבדיקת יציבות התוצאה. ניסויי הסרת ההקשר, האימון החד-משימתי והמודל המבוסס על הודעה בלבד הורצו באתחול 13 בלבד, לשמירה על זמן ריצה סביר ב-Apple MPS. במשימת הכוונה דווחו accuracy, Macro-F1, Weighted-F1 ו-F1 לכל מחלקה; המדד המרכזי הוא Macro-F1, בשל חוסר האיזון בין המחלקות. במשימת החוסר דווחו accuracy, F1 ו-AUROC.

### 4.5 ניסויי אבליציה

ניסויי אבליציה בודק את תרומתו של רכיב באמצעות הסרתו בלבד ושמירת יתר התנאים. זהו מבחן ישיר לשאלה אם ההטיה האינדוקטיבית שהוטמעה בארכיטקטורה אכן מועילה, ולא רק תיאור תאורטי שלה [10]. נבדקו ארבע גרסאות:

- ללא הטמעה של סוג השורה, לבדיקת תרומתו של מבנה הפרש הקוד.
- ללא שורות הקשר, לבדיקת תרומת הקוד הסמוך לשינוי.
- אימון נפרד לכל משימה, לבדיקת התרומה של למידה רב-משימתית.
- TF-IDF על הודעת השינוי בלבד, לבדיקת דליפת מידע מתהליך התיג.

## 5. תוצאות

### 5.1 השוואת המודלים

טבלה 2: ממוצע תוצאות הבדיקה.

| מודל                     | דיוק כוונה | Macro-F1 כוונה | דיוק חסר | F1 חסר | AUROC חסר |
|--------------------------|------------|----------------|----------|--------|-----------|
| TF-IDF + LR              | 0.5132     | 0.4197         | 0.5734   | 0.5430 | 0.6123    |
| MLP                      | 0.4049     | 0.2961         | 0.5529   | 0.3293 | 0.5488    |
| BiGRU                    | 0.3998     | 0.3023         | 0.5822   | 0.4204 | 0.5942    |
| Hierarchical Transformer | 0.4065     | 0.3007         | 0.6725   | 0.6029 | 0.7352    |

### 5.2 סיווג כוונה

TF-IDF השיג את Macro-F1 הגבוה ביותר, 0.4197, לעומת 0.2961 עד 0.3023 במודלים העצביים. התוצאה מתיישבת עם תפקידם של מקטעי n-gram בייצוג טקסט [11]: במערך קטן יחסית, תבניות מילוליות מקומיות עשויות להספיק לזיהוי מילות מפתח, בלי ללמוד ייצוג עמוק. באתחול 13 הייתה feature\_or\_behavior\_change המחלקה הקלה ביותר, ואילו refactor\_cleanup הגיעה ל-F1 של 0.1642 ב-TF-IDF ול-0.0 במודל ההיררכי. מחלקה זו מהווה רק 8.5% מהנתונים, והניסוחים שלה חופפים לתיקוני תקלות ולשינויי התנהגות. המודל המבוסס על הודעת השינוי בלבד השיג Macro-F1 של 0.9855. מאחר שהתוויות נוצרו ממילות מפתח באותה הודעה, התוצאה אינה מעידה על הבנת קוד אלא על תלות בין מנגנון התיג לקלט.

### 5.3 זיהוי מימוש חסר

במשימת השלמות התמונה מתהפכת. המודל ההיררכי השיג F1 של 0.6029 ו-AUROC של 0.7352, התוצאות הגבוהות ביותר מבין המודלים שנבדקו. באתחול 13 הפיק TF-IDF שליליים נכונים, 172 חיוביים שגויים, 168 שליליים שגויים ו-202 חיוביים נכונים. המודל ההיררכי הפיק 346, 81, 167, 203 בהתאמה. מספר המימושים החסרים שנמצאו כמעט זהה, אך המודל ההיררכי הפחית ביותר ממחצית את ההתראות השגויות על שינויים שלמים. זהו היתרון הצפוי מהטיה אינדוקטיבית המתאימה למבנה הנתונים [10]: ה-Transformer משווה בין שורות [12], וסוג השורה מסמן אם כל תוכן נוסף, נמחק או נותר כהקשר. השילוב מסייע להבחין בין שינוי קצר ושלם לבין שינוי שנקטע.

#### 5.4 תוצאות ניסויי האבלציה

טבלה 3: תוצאות ניסויי האבלציה. כוכבית מסמנת מדד של ראש שלא אומן ולכן אינו משמש להשוואה.

| הגדרה            | מספר ריצות | Macro-F1 כוונה | F1 חסר  | AUROC חסר |
|------------------|------------|----------------|---------|-----------|
| מודל היררכי מלא  | 3          | 0.3007         | 0.6029  | 0.7352    |
| ללא סוג שורה     | 3          | 0.3028         | 0.4724  | 0.6294    |
| ללא שורות הקשר   | 1          | 0.2677         | 0.5937  | 0.7126    |
| אימון חסר בלבד   | 1          | 0.1813*        | 0.6354  | 0.7163    |
| אימון כוונה בלבד | 1          | 0.3193         | 0.5797* | 0.4947*   |

הסרת סוגי השורות הורידה את F1 במשימת השלמות ב-0.1305 ואת AUROC ב-0.1058, כמעט ללא שינוי ב-Macro-F1 של הכוונה. באתחול 13 ירד מספר החיוביים הנכונים מ-203 ל-137, בעוד מספר החיוביים השגויים נשאר 81. האבלציה קושרת אפוא בין העיקרון התאורטי לתוצאה הניסויית: ייצוג מפורש של ADD, DEL ו-CTX מספק למודל מידע מבני שאינו מתקבל מרצף אסימונים בלבד [10]. לעומת זאת, הניסויים החד-משימתיים אינם מראים יתרון ברור ללמידה רב-משימתית, אך הם מבוססים על אתחול יחיד ולכן המסקנה מוגבלת.

#### 6. ניתוח שגיאות ומגבלות

##### 6.1 סוגי המוטציות

טבלה 4: שיעור הזיהוי לפי סוג מוטציה באתחול האקראי 13.

| סוג מוטציה בקבוצת הבדיקה   | מספר דוגמאות | שיעור הזיהוי של המודל ההיררכי |
|----------------------------|--------------|-------------------------------|
| השמטת שורת ADD             | 304          | 0.6086                        |
| הסרת guard או assertion    | 58           | 0.2931                        |
| היפוך קבוע בינארי          | 6            | 0.0000                        |
| הסרת השמת reset או default | 2            | 0.5000                        |

82.2% מהדוגמאות החסרות בקבוצת הבדיקה נוצרו באמצעות השמטת שורת ADD. לכן המדד הכולל משקף בעיקר חסרים גלויים יחסית ואינו מודד באופן מאוזן את כל סוגי הטעות. המודל התקשה יותר בדוגמאות שבהן הוסרו guards או assertions, ונכשל בשם הדוגמאות של היפוך קבוע. בקבוצת הבדיקה לא הופיעו דוגמאות מסוג drop\_hunk, flip\_comparison\_operator או flip\_logical\_operator, ולכן אין בסיס להערכת מוטציות אלה. המגבלה נובעת מתהליך יצירת הנתונים, ולא בהכרח מכשל של הארכיטקטורה בכל אחד מסוגי המוטציה.

##### 6.2 דוגמאות איכותניות

חיוביים שגויים, כלומר שינויים שלמים שסומנו כחסרים, הופיעו בשינויים קטנים הקשורים לאות שער, לאתחול או להסרת הגדרות תצורה תקינות. שליליים שגויים, כלומר מימושים חסרים שלא זוהו, הופיעו כאשר השמטת שורה לא פגעה בקוהרנטיות הלכסיקלית של ההפרש, למשל בשינוי של parameter או assertion. הדפוס מסביר את הפער בין למידת מבנה לבין הבנת התנהגות: המודל מזהה יחסים בין אסימונים ושורות, אך אינו מריץ את המעגל ואינו בודק את משמעותו לאורך זמן.

##### 6.3 מחקרי הרחבה

הרחבת רשימות מילות המפתח הפחיתה את שיעור הדוגמאות שנפסלו מ-29% ל-16% ב-OpenTitan ומ-53% ל-25% ב-Caliptra וצמצמה את הפער בין הפרויקטים מ-24 נקודות אחוז ל-9, אך אינה פותרת הודעות המתארות מה השתנה במקום מדוע. מחקר ראשוני על Caliptra, פרויקט פתוח נוסף לחומרת אבטחה, מצא פרופיל שינויים שונה מאוד מזה של OpenTitan ושיעור פסילה גבוה יותר, ולכן אין להסיק ממנו הכללה בין פרויקטים. מודל Random Forest עם 18 מאפייני RTL הגיע באימות צולב בן חמישה קפלים ל-Macro-F1 של  $0.525 \pm 0.114$ , לעומת  $0.544 \pm 0.053$  ב-TF-IDF באותו פרוטוקול. היחס בין שורות שנוספו לנמחקו, גודל השינוי והופעת parameters היו המאפיינים הבולטים ביותר. תוצאות אלה משתמשות בנתונים ובפרוטוקול נפרדים ולכן אינן בוות השוואה ישירה לטבלה 3.

טבלה 5: סיכום מחקרי ההרחבה. המדדים חושבו על נתונים ובפרוטוקול נפרדים מהניסוי העיקרי.

| מדד/ניסוי                                 | ערך       |
|-------------------------------------------|-----------|
| שיעור פסילה בתיוג (אחרי → לפני) OpenTitan | 29% → 16% |
| שיעור פסילה בתיוג (אחרי → לפני) Caliptra  | 53% → 25% |

| ממד/ניסוי                                       | ערך               |
|-------------------------------------------------|-------------------|
| מאפייני<br>Macro-F1 (CV)<br>RTL + Random Forest | $0.525 \pm 0.114$ |
| TF-IDF<br>באותו פרוטוקול<br>Macro-F1 (CV)       | $0.544 \pm 0.053$ |

## 7. מסקנות

הפרויקט מראה שמבנה השינוי מועיל בזיהוי מימוש חסר. המודל ההיררכי הפחית התראות שווא, והאבלציה אישרה שסוגי השורות הם רכיב משמעותי. בכך מתקבל רצף עקבי בין התאוריה לניסוי: הטיה אינדוקטיבית המתאימה למבנה ההיררכי של השינוי מגדירה אילו יחסים המודל יכול לנצל [10,11,12]. לעומת זאת, במשימת הכוונה TF-IDF היה עדיף, והתוצאה הקיצונית של מודל ההודעה חשפה את מגבלת weak labeling. לכן אין להסיק שמודל עמוק עדיף בכל מצב.

## 8. תרומת חברי הצוות

קורן בנה את הבסיס, את צינור הנתונים (כריית השינויים מ-OpenTitan, הפירוק, התיג ויצירת החורים), את ארבעת המודלים ואת הארכיטקטורה ההיררכית, וכן את מערכת האימון, ניסויי האבלציה וההרצה המלאה. נועה עבדה על הניתוח וההרחבות שמעבר למודל הבסיסי. היא ניתחה לעומק כמה המודלים נכשלים בזיהוי הכוונה וחשפה את קריסת המחלקה הנדירה, שיפרה את מנגנון התיג כדי שיזרוק פחות דוגמאות, בדקה האם הגישה עובדת גם על פרויקט אחר (Caliptra), ובנתה מודל נוסף שמבוסס על מאפייני חומרה והעריכה אותו ב-cross-validation. בנוסף היא פיתחה את כלי העזר לסקירת קוד. את שאלות המחקר, הניתוח הביקורתי והמסקנות גיבשו יחד.

## מקורות

- [1] lowRISC, OpenTitan, <https://github.com/lowRISC/opentitan>.
- [2] T. Hoang, H. J. Kang, J. Lawall, D. Lo, CC2Vec: Distributed Representations of Code Changes, ICSE 2020, DOI 10.1145/3377811.3380361.
- [3] T. Hoang, J. Lawall, Y. Tian, R. J. Oentaryo, D. Lo, PatchNet: Hierarchical Deep Learning-Based Stable Patch Identification for the Linux Kernel, arXiv:1911.03576, 2019.
- [4] T. Hoang, H. K. Dam, Y. Kamei, D. Lo, N. Ubayashi, DeepJIT: An End-to-End Deep Learning Framework for Just-in-Time Defect Prediction, MSR 2019, DOI 10.1109/MSR.2019.00016.
- [5] Z. Li et al., Automating Code Review Activities by Large-Scale Pre-training, arXiv:2203.09095, 2022.
- [6] K. Hannes, N. Sebbag, DiffIntent-RTL, <https://github.com/korrenhannes/diffintent-rtl>.
- [7] S. Maymon, Deep Learning, Lectures 2-3: Feedforward Networks, Output Units and Cost Functions, Tel Aviv University, 2026.
- [8] S. Maymon, Deep Learning, Lectures 4-6: Architecture Design, Optimization and Backpropagation, Tel Aviv University, 2026.
- [9] S. Maymon, Deep Learning, Lectures 7-9: Regularization, Early Stopping and Dropout, Tel Aviv University, 2026.
- [10] S. Maymon, Deep Learning, Lectures 9-10: Convolutional Neural Networks and Inductive Bias for Structured Data, Tel Aviv University, 2026.
- [11] S. Maymon, Deep Learning, Lecture 11: Natural Language Processing, Tokenization, n-grams, Embeddings and Recurrent Networks, Tel Aviv University, 2026.
- [12] S. Maymon, Deep Learning, Lecture 12: Attention, Positional Encoding and Transformers, Tel Aviv University, 2026.